

# Kompleksowe sprawozdanie z analizy: Porównanie modeli uczenia maszynowego i zjawisko dryfu pojęciowego w klasyfikacji zużycia energii

## 1. Cel projektu

Głównym celem ćwiczenia była implementacja, optymalizacja oraz krytyczna ewaluacja wydajności siedmiu algorytmów uczenia maszynowego (w tym zaawansowanych architektur Ensemble Learning). Zadanie polegało na sklasyfikowaniu poziomu zużycia energii w inteligentnym budynku (niskie vs. wysokie) na podstawie 24-wymiarowej przestrzeni danych sensorycznych (temperatura, wilgotność, warunki atmosferyczne). Dodatkowym, wynikowym celem badawczym stała się weryfikacja zachowania modeli predykcyjnych w obliczu danych ułożonych chronologicznie i zjawiska dryfu pojęciowego.

## 2. Podbudowa teoretyczna wykorzystanych metod

Aby zapewnić zróżnicowanie podejść analitycznych, w projekcie wykorzystano modele o różnej charakterystyce matematycznej:

- **Metody oparte na dystansie:** K-Nearest Neighbors (KNN), który klasyfikuje obiekty na podstawie miary odległości (np. euklidesowej) w wielowymiarowej przestrzeni cech.
- **Metody probabilistyczne i regułowe:** Drzewo Decyzyjne (Decision Tree), które dokonuje rekurencyjnego podziału przestrzeni w celu maksymalizacji przyrostu informacji.
- **Metody gradientowe:** Sieć Neuronowa (MLPClassifier) ucząca się nieliniowych reprezentacji za pomocą algorytmu wstecznej propagacji błędów.
- **Metody zespołowe (Ensemble Learning):** \* *Bagging* oraz *Random Forest*, które skupiają się na redukcji wariancji poprzez uśrednianie wyników wielu niezależnych drzew (wzrost odporności na szum).
  - *Stacking*, czyli uczenie kaskadowe, w którym meta-model (arbiter) optymalizuje wagi zaufania dla prognoz generowanych przez modele bazowe.

## 3. Zbiór danych i Przetwarzanie (Data Preprocessing)

Wykorzystano zbiór energy.csv (Appliances Energy Prediction Dataset).

- **Definicja problemu i dyskretyzacja:** Zmienną docelową Appliances (zużycie ciągłe w Wh) przekształcono w problem klasyfikacji binarnej. Ustalono twardy próg odcięcia na poziomie globalnej mediany zużycia (60 Wh). Wartości  $\leq 60$  Wh przypisano do klasy 0, a wartości  $> 60$  Wh do klasy 1.
- **Rozmiar próby:** Z uwagi na optymalizację złożoności obliczeniowej, do eksperymentu wyodrębniono pierwsze 5000 wierszy chronologicznych.
- **Inżynieria cech i skalowanie:** Usunięto identyfikatory czasu oraz szum (rv1, rv2). Każdy estymator został hermetycznie zamknięty w obiekcie Pipeline wraz z transformatorem StandardScaler. Standaryzacja wymusiła rozkład o średniej równej 0 i wariancji 1 dla każdej cechy, co jest krytyczne dla prawidłowego działania algorytmów wymiarowych (KNN, MLP).

## 4. Konfiguracja hiperparametrów

Skonfigurowano 7 klasyfikatorów z następującymi ograniczeniami:

- **KNN:** 5 sąsiadów ( $n\_neighbors=5$ ).
- **Decision Tree:** Maksymalna głębokość podziałów równa 10 ( $max\_depth=10$ ), dla ochrony przed przetrenowaniem.
- **MLPClassifier:** Dwie warstwy ukryte (10 i 5 neuronów), zwiększony limit epok uczenia ( $max\_iter=1500$ ).
- **Random Forest:** Las 100 drzew decyzyjnych ( $n\_estimators=100$ ,  $max\_depth=10$ ).
- **Bagging:** Agregacja 50 drzew bazowych ( $n\_estimators=50$ ).
- **Soft Voting:** Uśrednianie prawdopodobieństw z modeli KNN, Drzewa i MLP.
- **Stacking:** Arbiter w postaci Regresji Logistycznej, bazujący na KNN, Drzewie i Random Forest.

## 5. Metodologia ewaluacji i Wyniki eksperymentalne

Walidację przeprowadzono techniką 5-krotnej walidacji krzyżowej (*5-fold Cross Validation*). Wyniki uśrednionej precyzji (Accuracy) posortowane malejąco przedstawia poniższe zestawienie:

| Pozycja | Nazwa Klasyfikatora     | Typ       | Średnia Dokładność |
|---------|-------------------------|-----------|--------------------|
| 1       | Stacking (Arbiter)      | Zespołowy | 50.42%             |
| 2       | Sieć Neuronowa (MLP)    | Bazowy    | 44.86%             |
| 3       | Random Forest           | Zespołowy | 43.86%             |
| 4       | Voting (Miękkie)        | Zespołowy | 40.98%             |
| 5       | Drzewo Decyzyjne        | Bazowy    | 40.44%             |
| 6       | K-Najbliższych Sąsiadów | Bazowy    | 40.14%             |
| 7       | Bagging (Drzewa)        | Zespołowy | 39.86%             |

## 6. Zaawansowana analiza wyników i zjawisko Concept Drift

Otrzymane rezultaty, oscylujące wokół 40-50%, są niższe niż prawdopodobieństwo klasyfikacji losowej w zbalansowanym zbiorze. Taka anomalia statystyczna dostarcza kluczowych informacji o naturze analizowanego zbioru:

1. **Szeregi czasowe i autokorelacja:** Zbiór `energy.csv` to dane ułożone ściśle chronologicznie. Wyodrębnienie pierwszych 5000 wierszy bez ich wcześniejszego wymieszania (`shuffling`) zachowało strukturę szeregu czasowego (np. ciągłe pomiary z zaledwie kilkunastu dni zimowych).
2. **Dryf pojęciowy (Concept Drift):** W procesie walidacji krzyżowej ( $CV=5$ ) zbiór dzielony jest na nienachodzące na siebie bloki. Algorytmy uczyły się specyficznych, chwilowych zależności z jednego bloku czasowego (np. nagłe ocieplenie), które w kolejnym bloku (np. froncie chłodnym) były już całkowicie nieprawdziwe. Algorytmy wykazały się tzw. ujemnym transferem wiedzy – wyuczone reguły przynosiły więcej szkody niż pożytku na nowym podzbiorze walidacyjnym.
3. **Mechanizm ratunkowy algorytmu Stacking:** Wyłącznie algorytm Stacking utrzymał skuteczność powyżej 50%. Regresja logistyczna pełniąc rolę sędziego (meta-estymatora) prawidłowo wykryła wysoką wariancję błędu modeli bazowych w czasie. Dzięki analizie logistycznej, algorytm potrafił "wyzerować" zaufanie do estymatorów generujących największy szum, co jest dowodem na ogromną elastyczność i przewagę architektur kaskadowych.

## 7. Rekomendacje i kierunki optymalizacji

Aby przekształcić uzyskane modele w stabilne systemy o dokładności na poziomie 80-90%, rekomenduje się wdrożenie następujących zmian inżynierskich:

- **Losowanie rozkładu (Shuffling):** Bezwzględne zastosowanie tasowania zbioru (`train_test_split` z parametrem `shuffle=True`) przed podziałem na próby. Pozwoli to zniszczyć chronologię i zbalansować zjawiska pogodowe w podzbiorach treningowych i testowych.
- **Alternatywna walidacja:** Zastąpienie standardowego *K-Fold CV* metodologią *TimeSeriesSplit*, która jest natywnie przystosowana do pracy z szeregami czasowymi, oceniając modele wyłącznie na danych historycznych.
- **Feature Engineering:** Ekstrakcja nowych, jawnych cech czasowych z kolumny `date` (np. *godzina*, *dzień tygodnia*, *czy\_weekend*). Zużycie energii zależy w głównej mierze od cyklu dobowego mieszkańców, a oparcie predykcji wyłącznie na temperaturze pozbawiło algorytmy kluczowego kontekstu behawioralnego.

## 8. Optymalizacja inżynierska i reewaluacja modeli

W odpowiedzi na zdiagnozowane zjawisko dryfu pojęciowego (Concept Drift) oraz bardzo niską skuteczność pierwotnych modeli (oscylującą w granicach 40-50%), przeprowadzono kompleksową optymalizację procesu przygotowania danych:

1. **Inżynieria Cech (Feature Engineering):** Z odrzuconej pierwotnie kolumny chronologicznej (`date`) wyekstrahowano nowe zmienne: *godzinę* (`hour`), *dzień tygodnia* (`day_of_week`) oraz *flagę weekendu* (`is_weekend`). Wymiarowość przestrzeni cech wzrosła tym samym z 24 do 26.
2. **Eliminacja korelacji czasowej:** Wyselekcjonowano próbkę 5000 rekordów poprzez losowanie z całego zbioru (`shuffle=True`), a nie poprzez sekwencyjne odcięcie pierwszych wierszy.

- Zoptymalizowana walidacja krzyżowa:** Zastosowano obiekt `KFold(n_splits=5, shuffle=True)`, aby zagwarantować pełną losowość w podziałach na zbiory treningowe i walidacyjne.

Po zastosowaniu powyższych zmian, wszystkie 7 klasyfikatorów zostało ponownie poddanych ewaluacji. Osiągnięte wyniki średniej dokładności (Accuracy) prezentuje poniższa tabela:

| Pozycja | Nazwa Klasyfikatora     | Typ       | Średnia Dokładność (Zoptymalizowana) | Skok względem cz. 1 |
|---------|-------------------------|-----------|--------------------------------------|---------------------|
| 1       | Random Forest           | Zespołowy | 82.50% (0.8250)                      | + 38.64 pp.         |
| 2       | Stacking (Arbiter)      | Zespołowy | 82.36% (0.8236)                      | + 31.94 pp.         |
| 3       | Bagging (Drzewa)        | Zespołowy | 81.70% (0.8170)                      | + 41.84 pp.         |
| 4       | Sieć Neuronowa (MLP)    | Bazowy    | 76.70% (0.7670)                      | + 31.84 pp.         |
| 5       | Voting (Miękkie)        | Zespołowy | 76.58% (0.7658)                      | + 35.60 pp.         |
| 6       | Drzewo Decyzyjne        | Bazowy    | 75.16% (0.7516)                      | + 34.72 pp.         |
| 7       | K-Najbliższych Sąsiadów | Bazowy    | 74.10% (0.7410)                      | + 33.96 pp.         |

## 9. Analiza porównawcza i wnioski końcowe

Zestawienie wyników przed i po optymalizacji dostarcza fundamentalnych dowodów na temat natury algorytmów uczenia maszynowego oraz wagi przygotowania danych (Data Preprocessing):

- Rozwiązanie problemu dryfu pojęciowego:** Wprowadzenie losowego tasowania danych (shuffling) przyniosło spektakularny wzrost skuteczności wszystkich modeli (skoki rzędu 31–41 punktów procentowych). Udowadnia to całkowicie postawioną wcześniej tezę: algorytmy w pierwszej iteracji nie uczyły się fizycznych zależności, lecz "przeuczały się" na tymczasowych korelacjach pogodowych. Wymieszanie danych wyrównało szanse i pozwoliło modelom generalizować wiedzę.

2. **Krytyczna rola kontekstu behawioralnego:** Dodanie cech reprezentujących upływ czasu (godzina, dzień) było kluczowe dla problemu zużycia energii w budynku. Sama temperatura na zewnątrz nie decyduje o zużyciu prądu – decyduje o nim to, czy mieszkańcy są w domu (godziny wieczorne, weekendy). Najlepiej ten nowy kontekst wykorzystata Sieć Neuronowa (MLP), która z przedostatniego miejsca (44.86%) awansowała na lidera modeli bazowych (76.70%).
3. **Wyższość zaawansowanych technik zespołowych (Ensembles):** Klasyfikatory oparte na "mądrości tłumu" zdeklasowały proste estymatory. Całe podium zajęły algorytmy oparte na agregacji drzew: Random Forest (82.50%), Stacking (82.36%) oraz Bagging (81.70%). Modele te natywnie potrafią ignorować szum informacyjny z 26 czujników i wybierać wyłącznie cechy decyzyjne.
4. **Stacking a Voting:** Wyniki ponownie obnażyły słabość głosowania miękkiego (Voting). Ponieważ uśrednia ono "demokratycznie" przewidywania wszystkich modeli, słabsze wyniki KNN (74.10%) i Drzewa (75.16%) pociągnęły wynik w dół (do 76.58%). Model Stacking, wykorzystujący Regresję Logistyczną jako sędziego, inteligentnie przydzielił niższe wagi słabym modelom bazowym, co pozwoliło mu osiągnąć niemal 82.4%.

#### **Podsumowanie i wnioski z eksperymentu:**

1. **Znaczenie przygotowania danych:** Ćwiczenie udowodniło starą zasadę analityki: algorytm jest tylko tak dobry, jak dane, na których się uczy. Skuteczność każdego z modeli wzrosła o ponad 30% po tym, jak przetasowaliśmy zbiór (co rozwiązało problem ułożenia danych chronologicznie) i dodaliśmy informacje o czasie (godzina, weekend). To pokazuje, że samo wrzucenie surowych danych z czujników do programu rzadko daje dobre efekty.
2. **Skuteczność pracy zespołowej:** W przypadku skomplikowanych danych pochodzących z wielu czujników (jak systemy Smart Home / IoT), znacznie lepiej sprawdzają się modele zespołowe (Random Forest, Stacking). Łączenie sił wielu prostych algorytmów (np. setek drzew decyzyjnych) daje stabilniejsze i pewniejsze wyniki niż próba stworzenia jednego, skomplikowanego super-modelu.
3. **Uwaga na wady uśredniania:** Na koniec warto zauważyć, że nie każde połączenie modeli jest dobre. Stacking okazał się skuteczniejszy od miękkiego głosowania (Voting), ponieważ potrafił sam zdecydować, którym bazowym algorytmem ufać bardziej, zamiast traktować wszystkie głosy równo, co ostatecznie zaniżałoby skuteczność całego systemu.